Universidad de Murcia
Máster en Bioinformática

Análisis filogenético de la familia de terpeno sintasas en *Cannabis sativa*

Autora: Laura Llamas López
Asignatura: Análisis de Datos Ómicos
Fecha: Febrero 2026

Índice

1. Preparación de secuencias **2**
1.1. Especie modelo: *Arabidopsis thaliana* 2
1.1.1. Estrategia de búsqueda en UniProt 2
1.1.2. Tratamiento de las proteínas inactivas 2
1.1.3. Conjunto final de *Arabidopsis thaliana* 3
1.2. Especie problema: *Cannabis sativa* 3
1.3. Secuencias *bona fide* como anclas filogenéticas 3

2. Identificación por homología (BLAST) **4**
2.1. Parámetros empleados 4
2.2. Filtrado de resultados 4
2.3. Conjunto final de candidatos 5

3. Alineamiento múltiple **5**

4. Filogenia **6**
4.1. Topología general 7
4.2. Relaciones de ortología 7
4.3. Notas sobre la subfamilia TPS-b/g 7
4.4. Control interno 7

5. Visualización (iTOL) y conclusiones **8**

Referencias bibliográficas **8**

Repositorio

Todos los archivos de este análisis (secuencias, alineamiento y árbol) están disponibles públicamente en el repositorio de GitHub:

https://github.com/laullamas/tps-cannabis-phylogeny.git

1. Preparación de secuencias

1.1. Especie modelo: *Arabidopsis thaliana*

Como especie modelo se seleccionó *Arabidopsis thaliana* (Brassicaceae), el organismo vegetal con la anotación funcional más completa disponible. Su genoma fue el primero de una planta en ser completamente secuenciado [1] y sus terpeno sintasas han sido objeto de caracterización exhaustiva tanto a nivel genómico [2] como bioquímico, lo que garantiza que las etiquetas funcionales utilizadas como referencia son fiables.

1.1.1. Estrategia de búsqueda en UniProt

Las secuencias se descargaron desde UniProt (https://www.uniprot.org) empleando el campo de familia de proteínas en lugar del nombre de gen o de la denominación de la proteína. Esta elección se justifica porque una consulta por nombre de gen (`gene:TPS`) recupera únicamente aquellas proteínas cuya denominación contiene explícitamente el acrónimo TPS, dejando fuera numerosos miembros relevantes de la familia que reciben nombres funcionales alternativos (GA1, GA2, geranyllinalool synthase, ent-kaurene synthase, copalyl diphosphate synthase, entre otros). El campo *family*, en cambio, agrupa las proteínas por pertenencia funcional con independencia de la nomenclatura, lo que garantiza una recuperación exhaustiva de todos los miembros de la familia.

La consulta utilizada fue:

```
(family:"terpene synthase") AND (organism_id:3702) AND (reviewed:true)
```

El campo `organism_id:3702` corresponde al identificador taxonómico NCBI de *Arabidopsis thaliana*, más preciso que el nombre literal. El filtro `reviewed:true` restringe los resultados a la sección Swiss-Prot, cuyas entradas han sido anotadas manualmente, excluyendo las entradas TrEMBL de anotación computacional. La búsqueda devolvió 34 resultados.

1.1.2. Tratamiento de las proteínas inactivas

Entre las 34 entradas Swiss-Prot figuran dos proteínas catalogadas como inactivas, es decir, pseudo-enzimas que conservan la estructura tridimensional característica de las terpeno sintasas pero han perdido la actividad catalítica. Ambas se examinaron individualmente antes de decidir su inclusión o exclusión,.

La entrada Q9FI27 (TPS20_ARATH, *Inactive terpenoid synthase 20*) posee nivel de evidencia PE = 1, lo que indica que su existencia y caracterización están respaldadas por evidencia experimental directa. La secuencia es de longitud completa (∼580 aminoácidos) y su inactividad ha sido confirmada bioquímicamente. Se decidió mantenerla en el conjunto de referencia, puesto que una secuencia completa ocupa correctamente su posición en el árbol filogenético y permite

identificar posibles ortólogos inactivos en *Cannabis sativa*. Además, el alineamiento múltiple de la sección 3 permitirá examinar qué posiciones han mutado respecto a las TPS activas.

La entrada P0CJ42 (OCISA_ARATH, *Putative inactive (E)-beta-ocimene synthase*) presenta, en cambio, nivel de evidencia PE = 5 (inferida únicamente por homología de secuencia) y una longitud de tan solo ∼67 aminoácidos, lo que la convierte en un fragmento de pseudogén más que en una proteína funcional o estructuralmente informativa. Al no cubrir los motivos conservados (DDxxD de clase I, DxDD de clase II), carece de poder discriminativo en la filogenia y, por su longitud reducida, corre el riesgo de generar el artefacto conocido como *long-branch attraction*. Se decidió, por tanto, eliminarla del conjunto final.

1.1.3. Conjunto final de Arabidopsis thaliana

El conjunto comprende **33 secuencias**, todas pertenecientes a Swiss-Prot (niveles de evidencia PE = 1, PE = 2 o PE = 3), e incluye representantes de todas las clases funcionales presentes en la especie: monoterpeno sintasas, sesquiterpeno sintasas, diterpeno sintasas bifuncionales, terpeno sintasas de función putativa no resuelta y una pseudo-enzima inactiva (TPS20). Las secuencias se encuentran en el archivo `tps_arath.fasta`, que constituye la *query* para la búsqueda BLAST de la sección 2 y el conjunto de referencia para el análisis filogenético de la sección 4.

1.2. Especie problema: *Cannabis sativa*

Como especie de interés se seleccionó *Cannabis sativa* (Cannabaceae) por la relevancia de su perfil terpénico, tanto desde el punto de vista farmacológico como industrial. Los terpenos dominantes de los tricomas glandulares de esta especie —β-mirceno, limoneno, β-cariofileno, linalool, α-pineno y α-humuleno— determinan el aroma característico de las distintas variedades y están siendo objeto de creciente interés científico por sus posibles efectos biológicos [3, 4]. La convergencia de interés farmacológico, bioquímico y genómico en una sola especie la convierte en un sistema especialmente adecuado para explorar la diversificación funcional de la familia TPS mediante un análisis comparativo con una especie modelo bien caracterizada.

El recurso genómico empleado como referencia es el ensamblaje ASM2916894v1 (accesión RefSeq GCF_029168945.1), producido por la Kangwon National University en 2023 a partir del cultivar Pink pepper (KNU-18-1, planta femenina). Se trata del genoma de referencia oficial de la especie en NCBI, lo que implica que ha superado controles de calidad adicionales respecto a otros ensamblajes disponibles. El genoma está ensamblado a nivel de cromosoma, con un N50 de contig de 23,5 Mb y un tamaño total de aproximadamente 770 Mb.

1.3. Secuencias *bona fide* como anclas filogenéticas

Para asignar subfamilia y función a las TPS de *Cannabis sativa* es necesario incluir secuencias con actividad enzimática demostrada experimentalmente (PE = 1, Swiss-Prot) que actúen como anclas en el árbol. Los criterios de selección fueron: (i) evidencia experimental directa (ECO:0000269); (ii) no estar presentes ya en `tps_arath.fasta`; (iii) aportar poder de resolución adicional en clados de interés para *Cannabis sativa* o cubrir subfamilias ausentes en *Arabidopsis thaliana*.

Las tres secuencias seleccionadas, compiladas en el archivo `bona_fide.fasta`, son las siguientes:

A7IZZ1 (tps1_cansa)
: (−)-Limoneno sintasa de *Cannabis sativa* (TPS-b, PE = 1) [5]. Constituye una de las primeras TPS de Cannabis caracterizadas bioquímicamente y es referencia canónica de la especie en filogenias de TPS. Su inclusión tiene además valor metodológico: su

contraparte RefSeq (NP_001384867.1) fue recuperada independientemente por BLAST, por lo que el par actúa como control interno de calidad; si el alineamiento es correcto, ambas secuencias deben quedar como ramas hermanas con longitud de rama próxima a cero en el árbol.

Q38710 (tpsdv_abigr)
Abietadieno sintasa de *Abies grandis* (TPS-d, PE = 1) [6]. Se emplea como *outgroup* de gimnosperma para enraizar el árbol filogenético.

R4YXW8 (tps2_cofar)
Linalool/mirceno/ocimeno sintasa de *Coffea arabica* (TPS-g, PE = 1) [7]. Secuencia bioquímicamente confirmada de una familia botánica distinta (Rubiaceae) que produce los mismos compuestos acíclicos dominantes de Cannabis.

2. Identificación por homología (BLAST)

Se realizó una búsqueda BLASTP (servidor web NCBI) utilizando las 33 secuencias de *Arabidopsis thaliana* (`tps_arath.fasta`) como *query* multi-FASTA contra `refseq_protein` restringida a `taxid:3483`. Buscar con la familia completa en lugar de secuencia a secuencia garantiza la recuperación de ortólogos de todos los subgrupos funcionales, incluidos los más divergentes.

2.1. Parámetros empleados

- ***E-value*:** 1×10^{-5}. Más estricto que el valor por defecto (0,05), suficiente para limitar falsos positivos sin excluir miembros divergentes (las TPS presentan un 25–30 % de identidad entre subfamilias).
- **Matriz:** BLOSUM62, estándar para el rango de identidades esperado (30–65 %).
- **Max target sequences:** 500 (valor por defecto: 100), para evitar truncar la recuperación en familias con expansiones en tándem.
- **Filtro de baja complejidad:** desactivado, para evitar enmascarar regiones funcionales y reducir artificialmente la puntuación de *hits* legítimos.

2.2. Filtrado de resultados

La búsqueda devolvió 68 *hits*. Se aplicaron cuatro criterios de filtrado secuenciales:

1. **Baja calidad de anotación.** Se eliminó 1 proteína marcada como «LOW QUALITY PROTEIN» por NCBI (XP_030500626.2). Las inconsistencias en el modelo génico habrían introducido *gaps* sistemáticos no informativos en el alineamiento.
2. **Secuencias parciales.** Se eliminó 1 candidata anotada explícitamente como *partial* (XP_060960133.1). Las secuencias parciales no cubren los motivos conservados DDxxD y DxDD y producen artefactos de *long-branch attraction*.
3. **Isoformas redundantes.** Se eliminaron 23 variantes de *splicing* alternativo. Se conservó la entrada canónica cuando existía, o la isoforma más larga en su ausencia. Las proteínas con el mismo nombre pero accesiones distintas (sin sufijo «isoform») se trataron como parálogos y se conservaron.
4. **Fragmentos cortos.** Se eliminaron 10 entradas con longitud inferior a 450 aa. Una TPS completa mide entre 500 y 900 aa.

2.3. Conjunto final de candidatos

El conjunto final comprende **33 candidatos** (`cannabis_tps_candidates.fasta`), con representantes de los cuatro grupos funcionales esperados: monoterpeno sintasas (mirceno, limoneno, α-pineno, MTS1), sesquiterpeno sintasas (humuleno, germacreno, nerolidol, farneseno), diterpeno sintasas de clase II (copalil difosfato sintasa) y diterpeno sintasas de clase I (ent-kaureno sintasa, geranilinalool sintasa).

3. Alineamiento múltiple

Para el alineamiento múltiple se construyó un único fichero multi-FASTA denominado `tps_arath_bonafide_cannabis_raw.fasta`, generado mediante la concatenación ordenada de los tres conjuntos de secuencias obtenidos en las secciones anteriores: `tps_arath.fasta` (33 TPS de *Arabidopsis thaliana*, Swiss-Prot), `bona_fide.fasta` (3 anclas bioquímicas, Swiss-Prot) y `cannabis_tps_candidates.fasta` (33 candidatos de *Cannabis sativa*, RefSeq). El fichero resultante contiene **69 secuencias** en total y constituye la entrada directa al algoritmo de alineamiento.

El alineamiento se realizó con MAFFT [8] (`https://mafft.cbrc.jp`, opción AUTO). El servidor seleccionó el algoritmo L-INS-i (alineación local por pares con refinamiento iterativo), apropiado para proteínas con uno o pocos dominios alineables y regiones terminales o de inserción no homólogas. El resultado es un alineamiento de **69 secuencias** con una longitud uniforme de **1 272 posiciones** (`tps_arath_bona_cannabis_aligned.fasta`).

Validación del alineamiento. El 93 % de las secuencias (64/69) contienen el motivo DDxxD de clase I. Las dos posiciones internas (xx) son variables entre subfamilias: la variante más frecuente es DDIYD (28 secuencias, ∼44 %). Esta variabilidad es biológicamente esperada, dado que las posiciones internas forman parte del entorno hidrofóbico de la cavidad activa y han divergido a lo largo de la evolución, mientras que los dos aspartatos flanqueantes y el aspartato final —responsables de la coordinación directa del Mg^{2+}— están prácticamente conservados en todas las secuencias. La Figura 1 muestra un detalle del alineamiento en la región del motivo DDxxD.

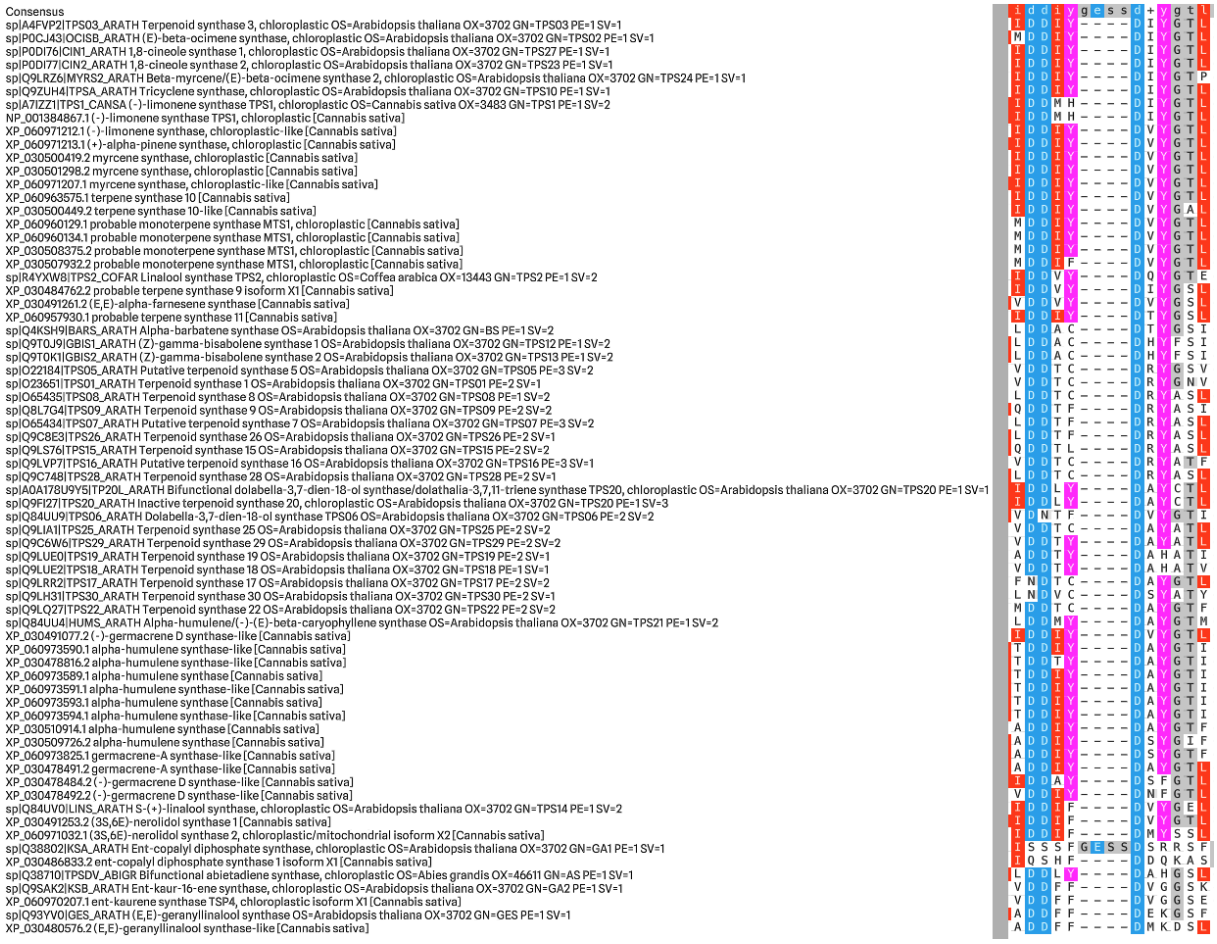

Figura 1: Detalle del alineamiento múltiple en la región del motivo conservado DDxxD de clase I. Se observa la conservación de los aspartatos flanqueantes (posiciones 1, 2 y 5 del motivo) y la variabilidad de las posiciones internas entre subfamilias.

Las 5 secuencias sin DDxxD tienen explicación biológica directa. KSA_ARATH y XP_030486833.2 son TPS de clase II (subfamilia TPS-c) que utilizan el motivo DxDD (DIDD) en lugar de DDxxD para la coordinación del sustrato. Las otras tres —TPS06_ARATH (dolabella-3,7-dien-18-ol sintasa, PE = 2), TPS17_ARATH y TPS30_ARATH (terpenoid synthase, PE = 2)— carecen completamente de ambos motivos canónicos; sus regiones ricas en aspartato están degeneradas o ausentes, lo que sugiere que son pseudoenzimas o TPS funcionalmente muy divergentes.

Como control interno, el fichero contiene dos registros del mismo locus de Cannabis (TPS1_CANSA de Swiss-Prot y NP_001384867.1 de RefSeq, identidad del 99,4 %). Si el alineamiento es correcto, ambas secuencias deben quedar adyacentes con longitud de rama próxima a cero en el árbol, aspecto que se verifica en la sección 4.

4. Filogenia

La inferencia filogenética se realizó por máxima verosimilitud con PhyML 3.3 [9, 10] a través de NGPhylogeny.fr [11].

El árbol resultante (`tree_tps_cannabis.nhx`) se enraizó en ABIGR_TPSDV (TPS-d, gimnosperma), cuya posición basal y rama larga (0,389 sust/sitio) confirman la correcta orientación del árbol.

4.1. Topología general

Las cinco subfamilias canónicas [12] se recuperan como grupos bien definidos (Tabla 1).

Tabla 1: Subfamilias TPS recuperadas en el árbol filogenético.

Subfamilia	Seqs	Descripción
TPS-d	1	*Outgroup*: ABIGR_TPSDV (abietadieno sintasa, *Abies grandis*)
TPS-c	2	Copalil difosfato sintasas (TPS de clase II); KSA_ARATH + ortólogo 1:1 en Cannabis (XP_030486833.2)
TPS-e/f	4	Diterpeno sintasas de clase I: ent-kaureno sintasas (1:1) y geranilinalool sintasas (1:1) en ambas especies
TPS-a	36	Sesquiterpeno sintasas; mayor expansión en Cannabis (clúster de 13 humuleno/germacreno sintasas frente a 1 en *Arabidopsis thaliana*)
TPS-b/g	26	Monoterpeno sintasas cloroplásticas; expansión en Cannabis (3 mirceno sintasas, varias limoneno, 4 MTS1)

4.2. Relaciones de ortología

La Tabla 2 resume las principales relaciones de ortología inferidas del árbol.

Tabla 2: Relaciones de ortología entre *Arabidopsis thaliana* y *Cannabis sativa*.

Arabidopsis thaliana	**Función**	***Cannabis sativa***	**Ratio**
KSA_ARATH	Copalil difosfato sintasa (GA1)	XP_030486833	1:1
KSB_ARATH	Ent-kaureno sintasa (GA2)	XP_060970207	1:1
GES_ARATH	Geranilinalool sintasa	XP_030480576	1:1
LINS_ARATH	*(S)*-Linalool sintasa	XP_030491253, XP_060971032	1:2
HUMS_ARATH	α-Humuleno/β-cariofileno sint.	13 humuleno/germacreno	1:13
MYRS2_ARATH	β-Mirceno/*(E)*-β-ocimeno sint.	XP_060971207, XP_030501298, XP_030500419	1:3

4.3. Notas sobre la subfamilia TPS-b/g

La secuencia XP_030491261 (*(E,E)*-α-farneseno sintasa) produce un sesquiterpeno (C15) pero se agrupa con las monoterpeno sintasas, resultado coherente con lo descrito previamente [5]: varias TPS de Cannabis productoras de sesquiterpenos presentan mayor similitud con TPS-b/g, lo que indica un origen evolutivo en el linaje de las monoterpeno sintasas con adquisición posterior de especificidad por FPP.

Por otro lado, XP_060957930 (TPS11-probable) ocupa una posición basal en TPS-b/g con rama larga ($\sim$0,42 sust/sitio), lo que la convierte en una posible candidata de especificidad desconocida de interés para caracterización bioquímica futura.

4.4. Control interno

Las dos entradas del mismo locus (TPS1_CANSA/NP_001384867.1) quedan como ramas hermanas con longitud de rama próxima a cero, lo que confirma que tanto el alineamiento como el árbol posicionan correctamente secuencias con relación conocida.

5. Visualización (iTOL) y conclusiones

El árbol Newick generado por PhyML (`tree_tps_cannabis.nhx`) se importó en iTOL v6 [13] con dos capas de anotación: color de etiqueta por origen taxonómico (azul = *Arabidopsis thaliana*, verde = *Cannabis sativa*, rojo = *bona fide*) y banda de color por subfamilia TPS, distinguiendo TPS-a, TPS-b/g, TPS-c, TPS-e/f y TPS-d (*outgroup*).

Del análisis se extraen las siguientes conclusiones:

1. Se identificaron 33 TPS de alta calidad en *Cannabis sativa* cubriendo las subfamilias presentes en angiospermas.
2. La ruta de giberelinas (TPS-c → TPS-e/f) está conservada con relaciones 1:1 estrictas entre ambas especies, lo que confirma su origen ancestral en angiospermas. Lo mismo ocurre con la geranilinalool sintasa (defensa volátil).
3. La subfamilia TPS-a muestra la expansión más pronunciada: el clúster de 13 humuleno/germacreno sintasas de Cannabis frente a 1 en *Arabidopsis thaliana* apunta a duplicaciones en tándem responsables de la abundancia de β-cariofileno y α-humuleno en el aceite esencial de la especie.
4. La subfamilia TPS-b/g también está amplificada (3 mirceno sintasas, varios limoneno sintasas, 4 MTS1 con ramas casi nulas entre sí), resultado coherente con el papel de β-mirceno y limoneno en la determinación del quimiotipo de Cannabis.
5. El análisis confirma que *Cannabis sativa* ha conservado la arquitectura funcional básica de la familia TPS de angiospermas mientras ha expandido selectivamente los linajes especializados en la producción de terpenos volátiles responsables de su perfil aromático y bioactivo característico.

Referencias bibliográficas

[1] The Arabidopsis Genome Initiative. Analysis of the genome sequence of the flowering plant *Arabidopsis thaliana*. *Nature*. 2000;408(6814):796–815.

[2] Chen F, Tholl D, Bohlmann J, Pichersky E. The family of terpene synthases in plants: a mid-size family of genes for specialized metabolism that is highly diversified throughout the kingdom. *Plant J.* 2011;66(1):212–29.

[3] Russo EB. Taming THC: potential cannabis synergy and phytocannabinoid-terpenoid entourage effects. *Br J Pharmacol.* 2011;163(7):1344–64.

[4] Hazekamp A, Fischedick JT. Cannabis – from cultivar to chemovar. *Drug Test Anal.* 2012;4(7-8):660–7.

[5] Booth JK, Page JE, Bohlmann J. Terpene synthases from *Cannabis sativa*. *PLoS One*. 2017;12(3):e0173911.

[6] Vogel BS, Wildung MR, Vogel G, Croteau R. Abietadiene synthase from grand fir (*Abies grandis*). cDNA isolation, characterization, and bacterial expression of a bifunctional diterpene cyclase involved in resin acid biosynthesis. *J Biol Chem.* 1996;271(38):23262–8.

[7] Del Terra L, Lonzarich V, Asquini E, Navarini L, Graziosi G, Suggi Liverani F, et al. Functional characterization of three *Coffea arabica* L. monoterpene synthases: insights into the enzymatic machinery of coffee aroma. *Phytochemistry*. 2013;89:6–14.

[8] Katoh K, Standley DM. MAFFT multiple sequence alignment software version 7: improvements in performance and usability. *Mol Biol Evol.* 2013;30(4):772–80.

[9] Guindon S, Gascuel O. A simple, fast, and accurate algorithm to estimate large phylogenies by maximum likelihood. *Syst Biol.* 2003;52(5):696–704.

[10] Guindon S, Dufayard JF, Lefort V, Anisimova M, Hordijk W, Gascuel O. New algorithms and methods to estimate maximum-likelihood phylogenies: assessing the performance of PhyML 3.0. *Syst Biol.* 2010;59(3):307–21.

[11] Lemoine F, Correia D, Lefort V, Doppelt-Azeroual O, Mareuil F, Cohen-Boulakia S, et al. NGPhylogeny.fr: new generation phylogenetic services for non-specialists. *Nucleic Acids Res.* 2019;47(W1):W260–5.

[12] Bohlmann J, Meyer-Gauen G, Croteau R. Plant terpenoid synthases: molecular biology and phylogenetic analysis. *Proc Natl Acad Sci U S A.* 1998;95(8):4126–33.

[13] Letunic I, Bork P. Interactive Tree of Life (iTOL) v6: recent updates to the phylogenetic tree display and annotation tool. *Nucleic Acids Res.* 2024;52(W1):W78–82.